TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN NGỌC TÂN
MSSV: 224308

TÊN ĐỀ TÀI:
HỆ THỐNG PHÂN TÍCH - XÁC THỰC ẢNH THẬT / GIẢ

ĐỒ ÁN CƠ SỞ 02

Ngành: Công Nghệ thông Tin

Mã số ngành: 7480201

Tháng 3 năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ

KHOA CÔNG NGHỆ THÔNG TIN

NGUYỄN NGỌC TÂN - 224308

LỚP: DH22TIN03

TÊN ĐỀ TÀI:

HỆ THỐNG PHÂN TÍCH - XÁC THỰC ẢNH THẬT / GIẢ

ĐỒ ÁN CƠ SỞ 02

NGÀNH: CÔNG NGHỆ THÔNG TIN

Mã số ngành: 7480201

GIẢNG VIÊN HƯỚNG DẪN

TRẦN VĂN THIỆN

Tháng 3 năm 2026

LỜI CẢM TẠ

Đầu tiên , em xin gửi tới quý Thầy Cô khoa Công nghệ Thông tin – Trường Đại học Nam Cần Thơ lời chào trân trọng, lời chúc sức khỏe và lời cảm ơn chân thành, sâu sắc nhất.

Trong suốt quá trình học tập tại trường, em luôn nhận được sự giảng dạy tận tình, sự quan tâm và định hướng quý báu từ quý Thầy Cô. Đặc biệt, nhờ vào sự chỉ dẫn chu đáo và hỗ trợ nhiệt tình của quý Thầy Cô, em đã hoàn thành Đồ án cơ sở 2 với đề tài: "Hệ thống phân tích - xác thực ảnh thật giả".

Em xin bày tỏ lòng biết ơn sâu sắc đến toàn thể quý Thầy Cô trong khoa Công nghệ Thông tin, những người đã truyền đạt cho em nền tảng kiến thức chuyên môn vững chắc và kinh nghiệm quý giá, tạo điều kiện cho em hoàn thành tốt đề tài này.

Đồ án vẫn không tránh khỏi những thiếu sót nhất định. Em rất mong nhận được những ý kiến đóng góp, nhận xét quý báu từ quý Thầy Cô để em có cơ hội hoàn thiện bản thân, nâng cao kiến thức và phục vụ tốt hơn cho công việc sau này.

Em xin chân thành cảm ơn!

Cần Thơ, ngày 22 tháng 3 năm 2026

Sinh viên thực hiện

Nguyễn Ngọc Tân

LỜI CAM KẾT

Chúng em xin cam kết với quý Thầy , Cô và Hội Đồng Trường đại học Nam Cần Thơ , đồ án này được tạo ra dựa trên kiến thức trong quá trình học tập tại trường và những thông tin nghiên cứu có liên quan đến đề tài . Kết quả này chưa từng được dùng cho bất kỳ khóa đồ án nào trước đây.

Cần Thơ, ngày 22 tháng 3 năm 2026

Sinh viên thực hiện

Nguyễn Ngọc Tân

NHẬN XÉT ĐÁNH GIÁ CỦA GIÁO VIÊN HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần Thơ, ngày 22 tháng 3 năm 2026

Giảng viên hướng dẫn

Trần Văn Thiện

NHẬN XÉT ĐÁNH GIÁ CỦA GIÁO VIÊN PHẢN BIỆN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Cần thơ, ngày 22 tháng 3 năm 2026

Giảng viên phản biện

MỤC LỤC

CHƯƠNG 1 GIỚI THIỆU 1
1.1 Bối cảnh nghiên cứu 1
1.2 Vấn đề hiện tại 1
1.3 Hạn chế của đề tài 2
1.4 Giải pháp đề xuất 2
1.5 Mục tiêu của đề tài 2
CHƯƠNG 2 CƠ SỞ LÝ LUẬN VÀ PHƯƠNG PHÁP NGHIÊN CỨU 4
2.1 Cơ sở lý luận 4
2.1.1 AI tạo ảnh (GAN và Diffusion) 4
2.1.2 Phát hiện ảnh AI 4
2.1.3 Các mô hình Deep Learning phổ biến 4
2.1.4 Explainable AI (Grad-CAM) 5
2.1.5 Các độ đo đánh giá mô hình 5
2.2 Phương pháp nghiên cứu 6
2.2.1 Dataset 6
2.2.2 Tiền xử lý dữ liệu 6
2.2.3 Mô hình và huấn luyện 7
2.2.4 Cấu hình huấn luyện 7
2.2.5 Grad-CAM trong hệ thống 7
CHƯƠNG 3 KIẾN TRÚC HỆ THỐNG 9
3.1 Tổng quan hệ thống 9
3.2 Thành phần hệ thống 9
3.3 Công nghệ sử dụng 12
CHƯƠNG 4 PHƯƠNG PHÁP NGHIÊN CỨU 13

4.1 Dataset 13

4.2 Tiền xử lý dữ liệu 13

4.3 Mô hình deep learning 14

4.4 Cấu hình huấn luyện 15

4.5 Grad-CAM 15

CHƯƠNG 5 KẾT QUẢ THỰC NGHIỆM 16

5.1 So sánh các Model 16

5.2 Confusion Matrix 17

5.3 Grad-CAM kết quả 20

CHƯƠNG 6 THẢO LUẬN 21

6.1 Mô hình nào tốt nhất và lý do 21

6.2 Phân tích vùng chú ý (grad-cam) 21

6.3 Hạn chế của hệ thống 21

CHƯƠNG 7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 23

7.1 Kết luận 23

7.2 Hướng phát triển 23

TÀI LIỆU THAM KHẢO 24

DANH SÁCH BẢNG

DANH SÁCH HÌNH

Hình 3.1. Tổng quan hệ thống 9

Hình 3.2. Lưu đồ quy trình xử lý hệ thống 11

Hình 4.1. ví dụ ảnh thật và ảnh AI trong Dataset 13

Hình 4.2. Minh họa các phép biến đổi dữ liệu 14

Hình 4.3. Kiến trúc mô hình EfficientNet-B0 15

Bảng 5.1. bảng so sánh hiệu năng các mô hình 16

Hình 5.2 Confusion Matrix của EfficientNet-B0 17

Hình 5.3 Confusion Matrix của ResNet18 18

Hình 5.4 Confusion Matrix của ResNet50 18

Hình 5.5 Confusion Matrix của MobileNetV3-Large 19

Hình 5.6 Confusion Matrix của ConvNeXt-Tiny 19

Hình 5.7 Grad – CAM minh họa 20

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Nghĩa đầy đủ	Giải thích
AI	Artificial Intelligence	Trí tuệ nhân tạo
GAN	Generative Adversarial Network	Mạng sinh đối kháng
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
DL	Deep Learning	Học sâu
XAI	Explainable Artificial Intelligence	Trí tuệ nhân tạo có thể giải thích
Grad-CAM	Gradient-weighted Class Activation Mapping	Phương pháp trực quan hóa vùng chú ý của mô hình
API	Application Programming Interface	Giao diện lập trình ứng dụng
ROC-AUC	Receiver Operating Characteristic - Area Under Curve	Diện tích dưới đường cong ROC
TP	True Positive	Dự đoán đúng lớp dương
TN	True Negative	Dự đoán đúng lớp âm
FP	False Positive	Dự đoán sai lớp dương
FN	False Negative	Dự đoán sai lớp âm
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
RAM	Random Access Memory	Bộ nhớ truy cập ngẫu nhiên
VRAM	Video RAM	Bộ nhớ đồ họa
UI	User Interface	Giao diện người dùng
UX	User Experience	Trải nghiệm người dùng

FPS	Frames Per Second	Số khung hình mỗi giây
p50 / p95	Percentile 50 / 95	Độ trễ trung vị / độ trễ cao

CHƯƠNG 1 GIỚI THIỆU

1.1 Bối cảnh nghiên cứu

Trong những năm gần đây, trí tuệ nhân tạo (AI) phát triển mạnh mẽ, đặc biệt ở lĩnh vực tạo sinh nội dung. Các mô hình tạo ảnh như GAN và diffusion đã đạt được bước tiến vượt bậc, cho phép tạo ra hình ảnh có độ phân giải cao, màu sắc tự nhiên và chi tiết gần như ảnh chụp thật. Nhờ khả năng huấn luyện trên tập dữ liệu lớn, các mô hình này có thể tái hiện khuôn mặt người, phong cảnh hay vật thể với độ chân thực rất cao, khiến ranh giới giữa ảnh thật và ảnh giả ngày càng mờ nhạt. Song song với lợi ích trong sáng tạo nội dung, AI tạo ảnh cũng gây ra nhiều thách thức. Ảnh giả do AI tạo có thể bị lợi dụng để lan truyền thông tin sai lệch, làm giả chứng cứ, hoặc gây ảnh hưởng tiêu cực đến uy tín cá nhân và tổ chức. Việc phát hiện ảnh giả bằng mắt thường gần như không còn đáng tin cậy, nhất là khi các công cụ chỉnh sửa và tạo ảnh ngày càng dễ tiếp cận với mọi người. Điều này tạo ra nhu cầu cấp thiết về các hệ thống tự động có khả năng phân biệt ảnh thật và ảnh do AI tạo. Trong bối cảnh đó, nghiên cứu xây dựng hệ thống xác thực ảnh thật/giả không chỉ mang tính học thuật mà còn có giá trị thực tiễn cao. Một hệ thống hiệu quả sẽ góp phần nâng cao độ tin cậy của thông tin hình ảnh, hỗ trợ truyền thông minh bạch và giảm thiểu rủi ro từ nội dung giả trong môi trường số.

1.2 Vấn đề hiện tại

Vấn đề lớn nhất hiện nay là việc phân biệt ảnh thật và ảnh do AI tạo ngày càng khó khăn. Các mô hình tạo ảnh hiện đại có thể tạo ra hình ảnh với độ sắc nét, ánh sáng và chi tiết gần như ảnh chụp thật, khiến con người rất khó nhận biết bằng mắt thường. Ngay cả những người có kinh nghiệm cũng có thể bị đánh lừa khi ảnh giả được tạo ra hoặc chỉnh sửa một cách tinh vi. Ảnh giả do AI tạo đang gây ra nhiều hệ lụy nghiêm trọng. Trước hết là tin giả, khi hình ảnh bị chỉnh sửa hoặc tạo mới được sử dụng để định hướng dư luận hoặc gây hiểu lầm trong truyền thông. Thứ hai là deepfake, trong đó khuôn mặt hoặc hành động của người thật bị giả mạo, dẫn đến nguy cơ tổn hại danh dự, uy tín cá nhân và có thể gây ra hậu quả pháp lý. Thứ ba là lừa đảo, khi ảnh giả được sử dụng để tạo lòng tin giả mạo trong các giao dịch trực tuyến, quảng cáo hoặc các hình thức lừa đảo tài chính. Những rủi ro này làm giảm mức độ tin cậy của thông tin hình ảnh, tạo ra thách thức lớn cho cá nhân, tổ chức và cơ quan truyền thông. Do đó, cần có các hệ thống tự động và đáng tin cậy để hỗ trợ phát hiện ảnh AI, nhằm giảm thiểu tác động tiêu cực từ nội dung giả trong môi trường số.

1.3 Hạn chế của đề tài

Trong bối cảnh ảnh AI ngày càng tinh vi, con người rất khó nhận biết đâu là ảnh thật và đâu là ảnh giả chỉ bằng quan sát trực quan. Những dấu hiệu bất thường như chi tiết méo, ánh sáng lệch hay kết cấu phi tự nhiên ngày càng bị các mô hình tạo ảnh che giấu hiệu quả. Điều này khiến việc đánh giá bằng mắt thường trở nên thiếu tin cậy, đặc biệt khi ảnh có chất lượng cao hoặc được hậu kỳ kỹ lưỡng. Bên cạnh đó, các phương pháp truyền thống không còn hiệu quả. Những cách kiểm tra thủ công như đối chiếu bằng cảm quan, truy xuất nguồn gốc ảnh hoặc kiểm tra metadata thường không đủ nhanh, không nhất quán và dễ bị qua mặt. Hơn nữa, metadata có thể bị xóa hoặc chỉnh sửa, còn việc kiểm chứng nguồn gốc đòi hỏi nhiều thời gian và công sức. Vì vậy, các hạn chế này cho thấy cần có giải pháp tự động dựa trên học máy để phát hiện ảnh AI. Tuy nhiên, chính bản thân đề tài cũng đối mặt với thách thức: dữ liệu ảnh giả thay đổi nhanh, mô hình có thể bị giảm hiệu quả khi gặp dạng ảnh mới chưa từng thấy, và yêu cầu tài nguyên tính toán vẫn là rào cản khi triển khai ở quy mô lớn. Đây là những hạn chế cần được xem xét trong phạm vi nghiên cứu và cũng là hướng cải tiến cho các nghiên cứu tiếp theo.

1.4 Giải pháp đề xuất

Để khắc phục hạn chế của phương pháp thủ công và truyền thống, đề tài đề xuất sử dụng Deep Learning làm hướng tiếp cận chính. Các mô hình học sâu có khả năng tự động trích xuất đặc trưng phức tạp từ hình ảnh, từ đó phát hiện những dấu hiệu tinh vi mà con người khó nhận ra. Điều này đặc biệt phù hợp với bài toán phân biệt ảnh thật và ảnh do AI tạo, nơi ranh giới ngày càng mờ nhạt. Giải pháp tập trung vào việc tự động phân loại ảnh thành hai lớp: ảnh thật và ảnh giả. Hệ thống sử dụng mạng nơ-ron tích chập (CNN) để học đặc trưng thị giác ở nhiều mức độ, kết hợp mô hình hiệu quả như EfficientNet để đảm bảo cân bằng giữa độ chính xác và tốc độ. Quy trình bao gồm tiền xử lý ảnh, suy luận qua mô hình đã huấn luyện, và trả về nhãn cùng độ tin cậy. Ưu điểm của giải pháp này là khả năng xử lý nhanh, nhất quán và có thể mở rộng khi dữ liệu tăng lên. Đồng thời, hệ thống có thể tích hợp vào API và giao diện web để phục vụ người dùng thực tế. Việc áp dụng Deep Learning không chỉ giúp nâng cao độ chính xác phát hiện ảnh giả mà còn tạo nền tảng cho các ứng dụng kiểm chứng nội dung hình ảnh trong môi trường số.

1.5 Mục tiêu của đề tài

Mục tiêu cốt lõi của đề tài là xây dựng một hệ thống có khả năng phân loại ảnh thật và ảnh do AI tạo một cách tự động, chính xác và có thể triển khai thực tế. Hệ thống cần tiếp nhận ảnh đầu vào từ người dùng, xử lý qua mô hình học sâu, sau đó trả về kết quả phân loại kèm độ tin cậy để hỗ trợ người dùng hiểu và kiểm chứng kết quả. Bên cạnh mục tiêu về độ chính xác, đề tài hướng tới đánh giá và so sánh

nhiều mô hình khác nhau. Việc so sánh này giúp chọn được mô hình phù hợp nhất với yêu cầu triển khai, cân bằng giữa chất lượng dự đoán và tốc độ suy luận. Các mô hình được thử nghiệm gồm các kiến trúc phổ biến và hiệu quả như EfficientNet-B0, ResNet18, ResNet50, MobileNetV3-Large và ConvNeXt-Tiny. Mỗi mô hình được đánh giá trên cùng tập dữ liệu, cùng điều kiện huấn luyện và các chỉ số định lượng: Accuracy, Precision, Recall, F1, ROC-AUC; đồng thời đo thêm các chỉ số vận hành như độ trễ (p50, p95), throughput, RAM/VRAM sử dụng. Điều này giúp đề tài đưa ra kết luận khách quan về ưu/nhược điểm từng kiến trúc trong bài toán ảnh thật/giả. Một mục tiêu quan trọng khác là giải thích quyết định của mô hình thông qua Grad-CAM. Không chỉ dừng ở việc "dự đoán đúng", hệ thống cần chỉ ra vùng ảnh mà mô hình tập trung để giải thích vì sao ảnh được đánh giá là thật hay giả. Việc trực quan hóa này giúp tăng tính minh bạch, tạo lòng tin cho người dùng và hỗ trợ việc phân tích lỗi khi mô hình dự đoán sai. Ngoài ra, đề tài còn hướng đến khả năng triển khai và mở rộng: xây dựng API phục vụ suy luận thời gian thực, tích hợp giao diện web để người dùng thao tác dễ dàng, và có cơ chế lưu lịch sử dự đoán phục vụ kiểm tra lại. Qua đó, hệ thống không chỉ mang tính nghiên cứu mà còn có tính ứng dụng trong thực tế.

CHƯƠNG 2 CƠ SỞ LÝ LUẬN VÀ PHƯƠNG PHÁP NGHIÊN CỨU

2.1 Cơ sở lý luận

2.1.1 AI tạo ảnh (GAN và Diffusion)

AI tạo ảnh là lĩnh vực thuộc trí tuệ nhân tạo tạo sinh, trong đó mô hình có thể tạo ra hình ảnh mới dựa trên dữ liệu huấn luyện. Hai hướng chính hiện nay là GAN và Diffusion model.

GAN (Generative Adversarial Network) gồm hai mạng: Generator sinh ảnh và Discriminator phân biệt ảnh thật/giả. Hai mạng huấn luyện đối kháng giúp Generator tạo ảnh ngày càng giống thật. GAN tạo ảnh nhanh và sắc nét nhưng thường dễ gặp hiện tượng mất ổn định khi huấn luyện.

Diffusion model hoạt động theo cơ chế thêm nhiễu vào ảnh và học cách khử nhiễu để tạo ảnh mới. Các mô hình diffusion như Stable Diffusion cho chất lượng ảnh cao, chi tiết tốt và độ ổn định cao hơn GAN.

Sự phát triển của các mô hình này khiến ảnh AI ngày càng khó phân biệt với ảnh thật, tạo ra nhu cầu cấp thiết cho các hệ thống xác thực ảnh thật/giả.

2.1.2 Phát hiện ảnh AI

Phát hiện ảnh AI là bài toán phân loại nhằm xác định một ảnh đầu vào là ảnh thật hay ảnh do AI tạo. Trước đây, các phương pháp thủ công thường dựa vào dấu vết chỉnh sửa hoặc phân tích metadata. Tuy nhiên, các ảnh AI hiện đại rất tinh vi, khiến các dấu hiệu thủ công khó nhận biết và dễ bị qua mặt.

Hiện nay, hướng tiếp cận hiệu quả nhất là dùng học sâu để mô hình tự học đặc trưng phân biệt ảnh thật/giả. Các mô hình CNN có khả năng phát hiện các dấu hiệu tinh vi trong cấu trúc, kết cấu, ánh sáng hoặc nhiễu mà mắt người khó nhận ra. Nhờ đó, việc phát hiện ảnh AI trở nên chính xác và ổn định hơn, đặc biệt khi dữ liệu đa dạng.

Trong bối cảnh ảnh giả lan truyền nhanh và dễ gây hậu quả nghiêm trọng, việc xây dựng hệ thống phát hiện ảnh AI tự động là cần thiết. Nó không chỉ hỗ trợ kiểm chứng thông tin mà còn góp phần hạn chế tin giả, deepfake và các hành vi lừa đảo dựa trên hình ảnh.

2.1.3 Các mô hình Deep Learning phổ biến

Trong bài toán phân loại ảnh thật/giả, các mô hình CNN hiện đại thường được dùng làm backbone nhờ khả năng trích xuất đặc trưng mạnh. ResNet là kiến trúc nổi bật với cơ chế skip connection, giúp huấn luyện mạng sâu hiệu quả và ổn định. ResNet18 nhẹ và nhanh, ResNet50 sâu hơn nên có tiềm năng chất lượng tốt hơn.

EfficientNet là kiến trúc tối ưu hóa giữa độ chính xác và tài nguyên, sử dụng chiến lược compound scaling để cân bằng chiều sâu, chiều rộng và độ phân giải. EfficientNet-B0 thường được chọn cho các hệ thống cần hiệu năng tốt nhưng vẫn đảm bảo tốc độ suy luận.

MobileNet (ví dụ MobileNetV3-Large) được thiết kế cho môi trường hạn chế tài nguyên, sử dụng depthwise separable convolution để giảm số tham số và tăng tốc độ. Mặc dù nhẹ hơn, MobileNet vẫn đạt độ chính xác khá tốt trên nhiều bài toán phân loại ảnh.

Những mô hình này đều phù hợp để so sánh trong đề tài nhằm lựa chọn phương án tối ưu cho bài toán ảnh thật/giả.

2.1.4 Explainable AI (Grad-CAM)

Trong các hệ thống học sâu, một hạn chế lớn là mô hình thường hoạt động như "hộp đen", khó giải thích vì sao ra quyết định. Explainable AI (XAI) được đề xuất để làm rõ quá trình này, giúp người dùng hiểu mô hình đang dựa vào yếu tố nào trong ảnh.

Grad-CAM (Gradient-weighted Class Activation Mapping) là một phương pháp XAI phổ biến. Grad-CAM sử dụng gradient của lớp đầu ra với các feature map cuối cùng để tạo ra bản đồ nhiệt (heatmap) thể hiện vùng ảnh quan trọng nhất đối với dự đoán. Vùng màu nóng trên heatmap chính là khu vực mà mô hình "chú ý" khi phân loại ảnh.

Trong bài toán ảnh thật/giả, Grad-CAM giúp kiểm tra xem mô hình tập trung vào chi tiết nào trong ảnh để đưa ra kết luận. Điều này tăng tính minh bạch, tạo sự tin cậy cho người dùng và hỗ trợ phân tích lỗi khi mô hình dự đoán sai. Vì vậy, Grad-CAM được tích hợp vào hệ thống như một công cụ giải thích trực quan cho kết quả dự đoán.

2.1.5 Các độ đo đánh giá mô hình

Để đánh giá hiệu quả mô hình phân loại ảnh thật/giả, đề tài sử dụng các độ đo phổ biến trong học máy. Accuracy phản ánh tỷ lệ dự đoán đúng trên toàn bộ mẫu. Precision đo mức độ chính xác của các mẫu được dự đoán là dương, trong khi Recall thể hiện khả năng phát hiện đủ các ảnh AI (fake) thực sự. F1-score là trung bình điều hòa giữa Precision và Recall, giúp cân bằng hai yếu tố này. ROC-AUC đo khả năng phân biệt hai lớp trên nhiều ngưỡng khác nhau, thể hiện tính ổn định của mô hình. Confusion Matrix giúp quan sát trực quan số lượng dự đoán đúng/sai theo từng lớp.

Các công thức tính một số độ đo cơ bản được trình bày như sau:

Accuracy = (TP + TN) / (TP + TN + FP + FN)

Precision = TP / (TP + FP)

Recall = TP / (TP + FN)

F1-score = 2 * (Precision * Recall) / (Precision + Recall)

Ngoài các chỉ số chất lượng, đề tài còn đo độ trễ suy luận (latency p50/p95), thông lượng (throughput) và mức sử dụng tài nguyên RAM/VRAM để đánh giá khả năng triển khai thực tế. Việc kết hợp các chỉ số đánh giá chất lượng và hiệu năng giúp đảm bảo mô hình không chỉ chính xác mà còn phù hợp để triển khai trong môi trường thực tế.

2.2 Phương pháp nghiên cứu

2.2.1 Dataset

Bộ dữ liệu sử dụng trong đề tài gồm hai nhóm: ảnh thật (real images) và ảnh do AI tạo (AI-generated). Dữ liệu được tổ chức thành cấu trúc thư mục chuẩn để phục vụ huấn luyện và đánh giá mô hình. Tập dữ liệu được chia thành ba phần: train, validation và test nhằm đảm bảo quá trình huấn luyện, chọn mô hình và đánh giá cuối cùng được tách biệt rõ ràng.

Tỉ lệ chia dữ liệu được lựa chọn hợp lý để vừa đảm bảo đủ mẫu cho huấn luyện, vừa giữ tập test độc lập để đánh giá độ tổng quát của mô hình. Ngoài ra, số lượng ảnh giữa hai lớp được cân bằng nhằm tránh mô hình bị thiên lệch về một phía. Dữ liệu AI-generated có sự đa dạng về phong cách và chất lượng để mô hình có khả năng nhận diện tốt trên nhiều loại ảnh giả khác nhau.

Việc xây dựng dataset đầy đủ và cân bằng là nền tảng quan trọng giúp mô hình đạt độ chính xác cao và đảm bảo tính ổn định khi triển khai trong thực tế.

2.2.2 Tiền xử lý dữ liệu

Tiền xử lý là bước quan trọng giúp chuẩn hóa ảnh đầu vào và tăng độ ổn định cho mô hình. Trong đề tài, ảnh được đưa về kích thước thống nhất (ví dụ 224×224) để phù hợp với đầu vào của các backbone CNN. Sau đó, ảnh được chuyển sang tensor và chuẩn hóa (normalization) theo thống kê ImageNet, giúp mô hình học tốt hơn và hội tụ ổn định hơn.

Ngoài ra, trong quá trình huấn luyện có thể áp dụng data augmentation như lật ảnh, thay đổi độ sáng, xoay nhẹ hoặc làm mờ. Các phép biến đổi này giúp tăng sự đa dạng của dữ liệu, giảm hiện tượng overfitting và cải thiện khả năng tổng quát hóa của mô hình.

Việc tiền xử lý đúng cách đảm bảo ảnh đầu vào có định dạng thống nhất, giảm nhiễu và giúp mô hình tập trung vào các đặc trưng quan trọng. Đây là cơ sở để mô hình phân loại ảnh thật/giả đạt hiệu quả cao khi triển khai thực tế.

2.2.3 Mô hình và huấn luyện

Đề tài sử dụng các mô hình CNN hiện đại làm backbone, trong đó EfficientNet-B0 là mô hình chính nhờ khả năng cân bằng giữa độ chính xác và hiệu năng. Bên cạnh đó, các mô hình khác như ResNet18, ResNet50, MobileNetV3-Large và ConvNeXt-Tiny được huấn luyện để so sánh. Với mỗi backbone, lớp phân loại cuối được thay thế nhằm phù hợp với bài toán nhị phân thật/giả.

Các mô hình được khởi tạo từ trọng số pretrained trên ImageNet và fine-tuning trên tập dữ liệu của đề tài. Quá trình huấn luyện sử dụng hàm loss Cross-Entropy và tối ưu bằng thuật toán Adam. Sau mỗi epoch, mô hình được đánh giá trên tập validation để chọn checkpoint tốt nhất.

Mục tiêu của quá trình huấn luyện là tối ưu hóa chất lượng dự đoán, đồng thời đảm bảo thời gian suy luận phù hợp cho triển khai API. Việc huấn luyện nhiều mô hình khác nhau giúp so sánh hiệu năng và lựa chọn mô hình tối ưu cho hệ thống.

2.2.4 Cấu hình huấn luyện

Để đảm bảo so sánh công bằng giữa các mô hình, đề tài sử dụng cùng một cấu hình huấn luyện cho tất cả backbone. Các tham số chính bao gồm số epoch, batch size, optimizer và learning rate. Việc giữ cố định các tham số này giúp đánh giá đúng hiệu năng của từng kiến trúc thay vì bị ảnh hưởng bởi cấu hình khác nhau.

Trong thí nghiệm, mô hình được huấn luyện với số epoch đủ lớn để hội tụ, batch size phù hợp với tài nguyên phần cứng, và optimizer Adam để tăng tốc hội tụ. Learning rate được chọn ở mức vừa phải nhằm đảm bảo mô hình học ổn định và tránh dao động mạnh. Các chỉ số như accuracy và loss được theo dõi theo từng epoch để đánh giá tiến trình học và lựa chọn checkpoint tốt nhất.

Cấu hình huấn luyện thống nhất là yếu tố then chốt giúp kết quả benchmark giữa các mô hình mang tính khách quan và đáng tin cậy.

2.2.5 Grad-CAM trong hệ thống

Grad-CAM được tích hợp như một thành phần quan trọng trong hệ thống nhằm giải thích kết quả dự đoán. Sau khi mô hình đưa ra nhãn "thật" hoặc "giả", Grad-CAM tạo ra heatmap thể hiện vùng ảnh mà mô hình tập trung khi ra quyết định. Heatmap này được chồng lên ảnh gốc để người dùng dễ quan sát.

Trong hệ thống, Grad-CAM không chỉ giúp tăng tính minh bạch mà còn hỗ trợ phân tích lỗi, đặc biệt khi mô hình dự đoán sai. Nhờ đó, người dùng có thể thấy được liệu mô hình chú ý vào chi tiết bất thường nào trong ảnh.

Việc tích hợp Grad-CAM tạo ra điểm khác biệt so với các hệ thống chỉ trả kết quả nhị phân, giúp nâng cao độ tin cậy và giá trị ứng dụng của hệ thống trong thực tế.

CHƯƠNG 3 KIẾN TRÚC HỆ THỐNG

3.1 Tổng quan hệ thống

Hệ thống được thiết kế theo mô hình xử lý tuần tự (pipeline) để đảm bảo luồng dữ liệu rõ ràng và ổn định. Người dùng tải ảnh lên thông qua giao diện web, ảnh được gửi về backend để xử lý, sau đó mô hình học sâu thực hiện phân loại và trả kết quả. Luồng chính của hệ thống gồm các bước: Người dùng → Tải ảnh lên → Tiền xử lý → Mô hình học sâu → Dự đoán (Ảnh thật / Ảnh AI) → Grad-CAM → Hiển thị kết quả.

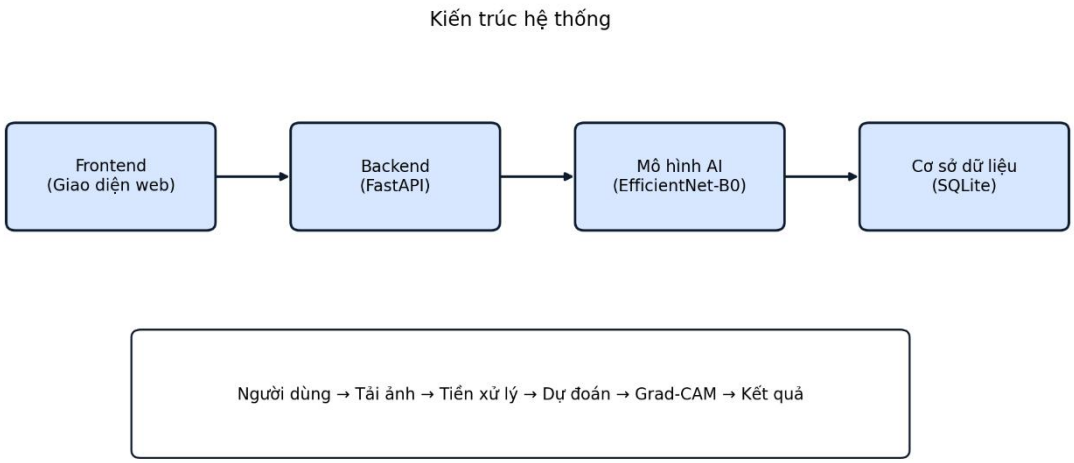

Hình 3.1. Tổng quan hệ thống

Ở bước tiền xử lý, ảnh đầu vào được chuẩn hóa về kích thước và định dạng phù hợp với mô hình CNN. Mô hình học sâu (EfficientNet-B0) nhận ảnh và trả về xác suất cho hai lớp thật/giả. Dựa trên kết quả này, hệ thống đưa ra nhãn dự đoán kèm độ tin cậy. Song song đó, Grad-CAM được tính toán để trực quan hóa vùng ảnh mà mô hình chú ý, giúp người dùng hiểu lý do dự đoán.

Kết quả cuối cùng được hiển thị trên giao diện bao gồm nhãn, độ tin cậy và ảnh Grad-CAM. Ngoài ra, hệ thống có khả năng lưu lịch sử dự đoán để phục vụ kiểm tra lại khi cần. Nhờ cách tổ chức này, hệ thống vừa đảm bảo tính chính xác, vừa thuận tiện cho người dùng và dễ triển khai trên môi trường thực tế.

3.2 Thành phần hệ thống

Hệ thống được chia thành bốn thành phần chính, phối hợp chặt chẽ để tạo ra quy trình phân tích ảnh hoàn chỉnh.

Thành phần thứ nhất là Frontend, đóng vai trò giao diện người dùng. Frontend cho phép tải ảnh lên (kéo-thả hoặc chọn file), hiển thị ảnh xem trước, hiển thị kết

quả dự đoán và trực quan hóa Grad-CAM. Giao diện được thiết kế đơn giản để người dùng thao tác nhanh và dễ hiểu.

Thành phần thứ hai là Backend, nơi xử lý logic chính. Backend nhận ảnh từ frontend, thực hiện tiền xử lý, gọi mô hình suy luận và trả kết quả. Ngoài ra, backend còn chịu trách nhiệm lưu lịch sử dự đoán vào cơ sở dữ liệu để phục vụ truy vết và kiểm tra sau này.

Thành phần thứ ba là Model AI, sử dụng các mô hình CNN đã huấn luyện để phân loại ảnh thật/giả. EfficientNet-B0 được chọn làm mô hình chính nhờ hiệu năng tốt, trong khi các mô hình khác được dùng để so sánh.

Thành phần thứ tư là Visualization, nơi tạo Grad-CAM để giải thích quyết định của mô hình. Heatmap được chồng lên ảnh gốc giúp người dùng hiểu mô hình tập trung vào vùng nào khi dự đoán.

Sự kết hợp của các thành phần này tạo thành hệ thống end-to-end, vừa chính xác, vừa dễ sử dụng và có khả năng triển khai thực tế.

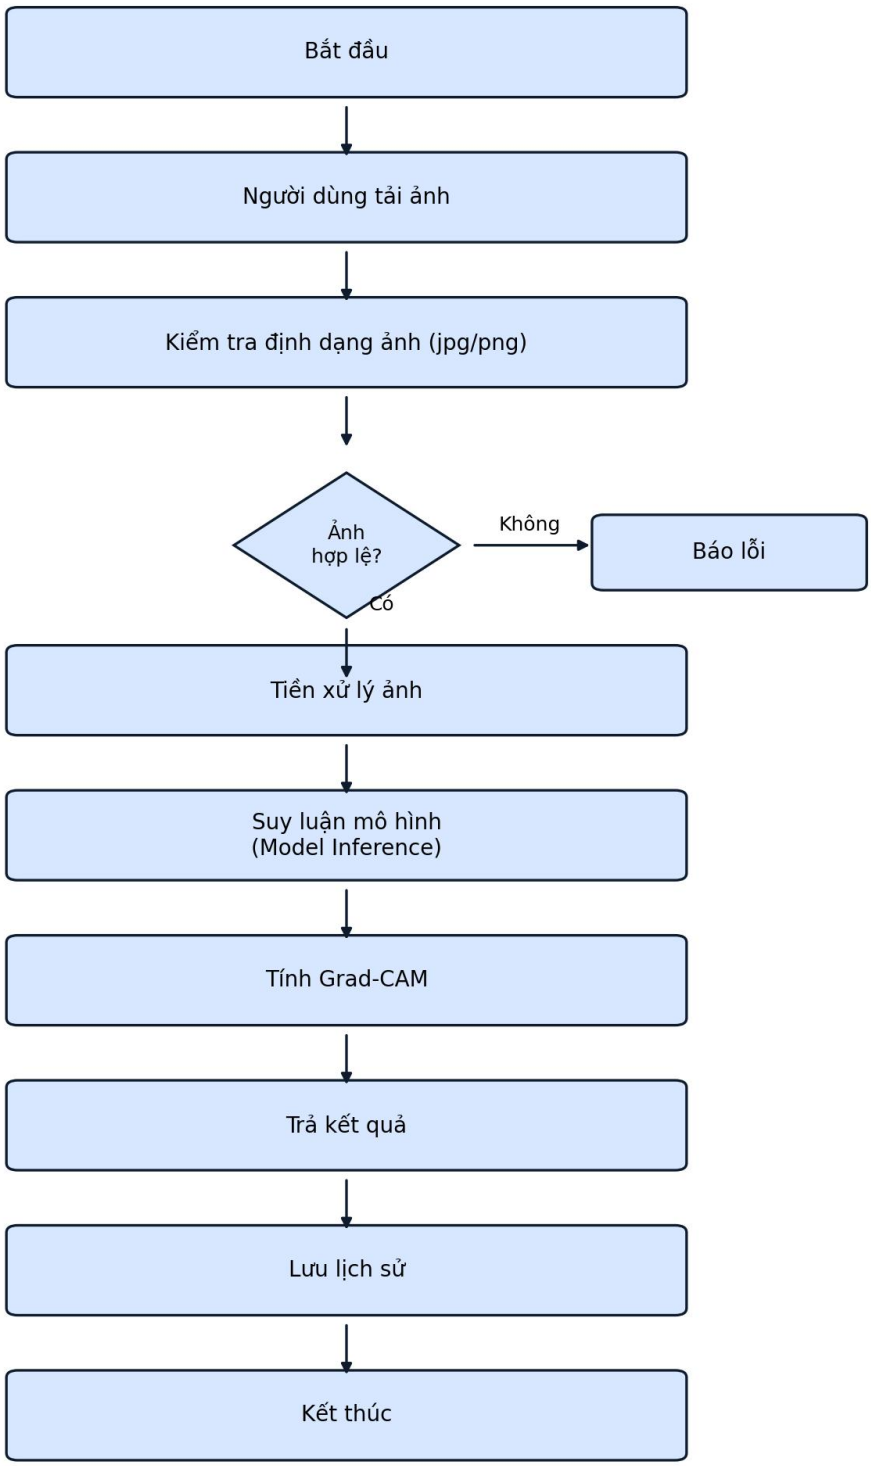

Hình 3.2. Lưu đồ quy trình xử lý hệ thống

3.3 Công nghệ sử dụng

Hệ thống sử dụng các công nghệ phù hợp để đảm bảo hiệu năng, tính ổn định và khả năng triển khai thực tế.

Trong phần AI/ML, ngôn ngữ Python và thư viện PyTorch được dùng để huấn luyện và suy luận mô hình. Torchvision cung cấp các backbone pretrained như EfficientNet, ResNet, MobileNet và ConvNeXt, giúp rút ngắn thời gian huấn luyện và cải thiện độ chính xác nhờ transfer learning.

Trong phần Backend, hệ thống sử dụng FastAPI để xây dựng các endpoint phục vụ dự đoán và truy vấn lịch sử. FastAPI có ưu điểm tốc độ cao, dễ mở rộng và hỗ trợ tốt cho triển khai thực tế.

Trong phần Frontend, hệ thống sử dụng HTML, CSS và JavaScript để xây dựng giao diện web. Giao diện hỗ trợ tải ảnh, hiển thị kết quả dự đoán và trực quan hóa Grad-CAM.

Cuối cùng, hệ thống dùng SQLite để lưu lịch sử dự đoán (thời gian, tên file, kết quả, độ tin cậy và ảnh gốc). Điều này giúp người dùng tra cứu lại các lần phân tích trước đó và phục vụ kiểm chứng khi cần.

Nhờ sự kết hợp các công nghệ trên, hệ thống vừa đáp ứng yêu cầu nghiên cứu, vừa đảm bảo khả năng vận hành trong môi trường thực tế.

CHƯƠNG 4 PHƯƠNG PHÁP NGHIÊN CỨU

4.1 Dataset

Bộ dữ liệu sử dụng trong đề tài gồm hai lớp: ảnh thật và ảnh do AI tạo. Dữ liệu được tổng hợp từ nhiều nguồn trên Kaggle và được tổ chức lại theo cấu trúc chuẩn để phục vụ huấn luyện và đánh giá mô hình. Tập dữ liệu được chia thành ba phần: train, validation và test, giúp quá trình huấn luyện, lựa chọn mô hình và kiểm thử được tách biệt rõ ràng.

Số lượng ảnh cụ thể như sau:

Train: 12,400 ảnh thật + 12,400 ảnh AI

Validation: 1,550 ảnh thật + 1,550 ảnh AI

Test: 1,550 ảnh thật + 1,550 ảnh AI

Tổng cộng 31,000 ảnh, với hai lớp cân bằng. Việc cân bằng dữ liệu giúp giảm thiên lệch trong quá trình huấn luyện và làm cho kết quả đánh giá khách quan hơn. Ngoài ra, do ảnh AI được lấy từ nhiều nguồn khác nhau, tập dữ liệu có tính đa dạng cao, giúp mô hình học được các đặc trưng tổng quát hơn và ổn định khi gặp ảnh mới.

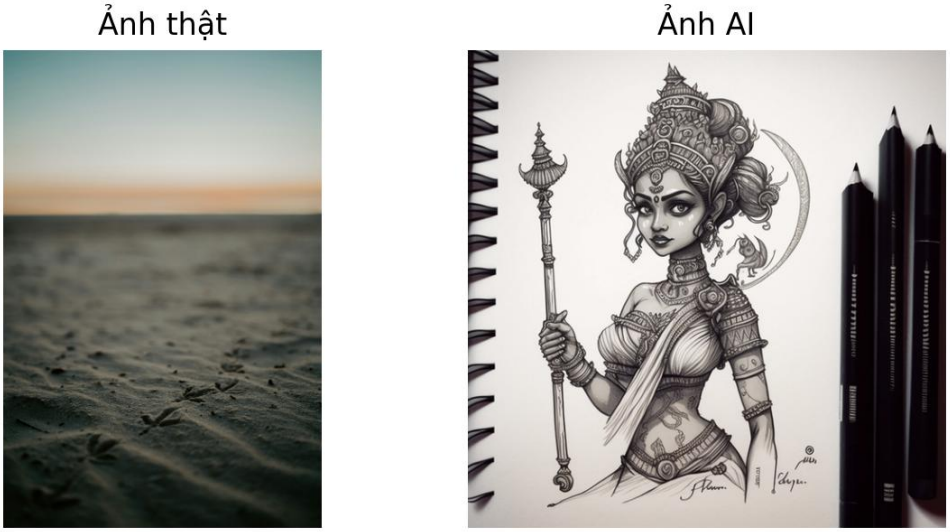

Hình 4.1. ví dụ ảnh thật và ảnh AI trong Dataset

4.2 Tiền xử lý dữ liệu

Trước khi đưa vào mô hình, ảnh được tiền xử lý để đảm bảo định dạng đầu vào thống nhất và giúp mô hình học ổn định hơn. Trong dự án, ảnh được resize về kích thước chuẩn, sau đó center crop để lấy vùng trung tâm và đưa về kích thước

đầu vào của mô hình (224×224). Ảnh tiếp tục được chuyển sang tensor và chuẩn hóa (normalization) theo thống kê ImageNet (mean, std), giúp giảm chênh lệch về phân phối dữ liệu và tăng tốc hội tụ khi huấn luyện.

Trong giai đoạn huấn luyện, có thể áp dụng data augmentation như lật ảnh, thay đổi độ sáng/độ tương phản hoặc làm mờ nhẹ để tăng tính đa dạng dữ liệu. Các phép biến đổi này giúp mô hình giảm overfitting và tổng quát tốt hơn khi gặp ảnh mới trong thực tế.

Quy trình tiền xử lý thống nhất được áp dụng cho tất cả mô hình nhằm đảm bảo so sánh công bằng giữa các backbone. Nhờ đó, kết quả đánh giá phản ánh đúng năng lực của từng mô hình thay vì bị ảnh hưởng bởi sự khác biệt trong khâu xử lý ảnh.

Hình 4.2. Minh họa các phép biến đổi dữ liệu

4.3 Mô hình deep learning

Đề tài sử dụng các mô hình CNN hiện đại để phân loại ảnh thật/giả, trong đó EfficientNet-B0 được chọn làm mô hình chính nhờ hiệu năng cân bằng giữa độ chính xác và tốc độ suy luận. Bên cạnh đó, các mô hình ResNet18, ResNet50, MobileNetV3-Large và ConvNeXt-Tiny cũng được huấn luyện để so sánh và đánh giá toàn diện.

Tất cả các backbone đều được khởi tạo từ trọng số pretrained trên ImageNet và fine-tuning trên tập dữ liệu của đề tài. Ở mỗi mô hình, lớp phân loại cuối được thay thế để phù hợp với bài toán nhị phân thật/giả. Cách tiếp cận này giúp tận dụng đặc trưng đã học sẵn, rút ngắn thời gian huấn luyện và cải thiện chất lượng dự đoán.

Việc triển khai nhiều mô hình giúp đánh giá được ưu/nhược điểm của từng kiến trúc trong bối cảnh hệ thống thực tế: ResNet ổn định, MobileNet nhẹ và nhanh, ConvNeXt có tiềm năng chất lượng cao, còn EfficientNet cho hiệu năng cân bằng tốt nhất.

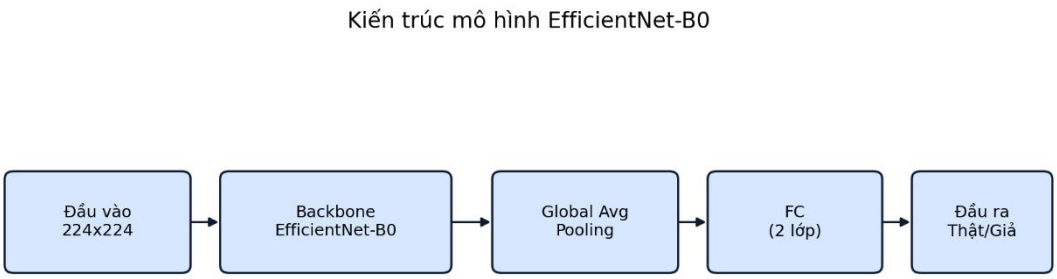

Hình 4.3. Kiến trúc mô hình EfficientNet-B0

4.4 Cấu hình huấn luyện

Để đảm bảo so sánh công bằng giữa các mô hình, đề tài sử dụng cùng một cấu hình huấn luyện cho tất cả backbone. Các tham số chính bao gồm số epoch, batch size, optimizer và learning rate. Trong dự án, batch size được đặt là 16 để phù hợp với tài nguyên phần cứng và đảm bảo quá trình huấn luyện ổn định.

Hàm mất mát sử dụng Cross-Entropy Loss cho bài toán phân loại nhị phân. Thuật toán tối ưu là Adam với learning rate ở mức nhỏ (ví dụ 1e-4) nhằm giúp mô hình hội tụ ổn định và giảm dao động. Sau mỗi epoch, mô hình được đánh giá trên tập validation, checkpoint tốt nhất được lưu lại dựa trên độ chính xác validation.

Việc thống nhất cấu hình giúp đánh giá đúng năng lực của từng mô hình thay vì bị ảnh hưởng bởi tham số huấn luyện khác nhau. Đây là bước quan trọng để đảm bảo các kết quả benchmark có ý nghĩa và có thể dùng để chọn mô hình tối ưu cho hệ thống thực tế.

4.5 Grad-CAM

Grad-CAM được sử dụng trong hệ thống để giải thích kết quả dự đoán của mô hình. Sau khi mô hình phân loại ảnh thành "thật" hoặc "AI", Grad-CAM tạo ra bản đồ nhiệt (heatmap) thể hiện vùng ảnh mà mô hình chú ý nhiều nhất khi ra quyết định. Heatmap này được chồng lên ảnh gốc để người dùng dễ quan sát.

Trong dự án, Grad-CAM được tích hợp trực tiếp vào API dự đoán, cho phép trả về cả nhãn dự đoán, độ tin cậy và ảnh trực quan hóa. Điều này giúp hệ thống không chỉ đưa ra kết quả nhị phân mà còn tăng tính minh bạch, tạo niềm tin cho người dùng.

Ngoài ra, Grad-CAM còn hỗ trợ quá trình phân tích lỗi: khi mô hình dự đoán sai, người dùng có thể kiểm tra xem mô hình đã tập trung vào vùng nào của ảnh. Từ đó, có thể cải thiện dữ liệu hoặc điều chỉnh mô hình trong các lần huấn luyện tiếp theo.

CHƯƠNG 5 KẾT QUẢ THỰC NGHIỆM

5.1 So sánh các Model

Để đánh giá hiệu năng, đề tài benchmark nhiều mô hình trên cùng tập test và cùng điều kiện huấn luyện. Các chỉ số được sử dụng gồm Accuracy, Precision, Recall, F1 và ROC-AUC, kèm các chỉ số vận hành như độ trễ và throughput.

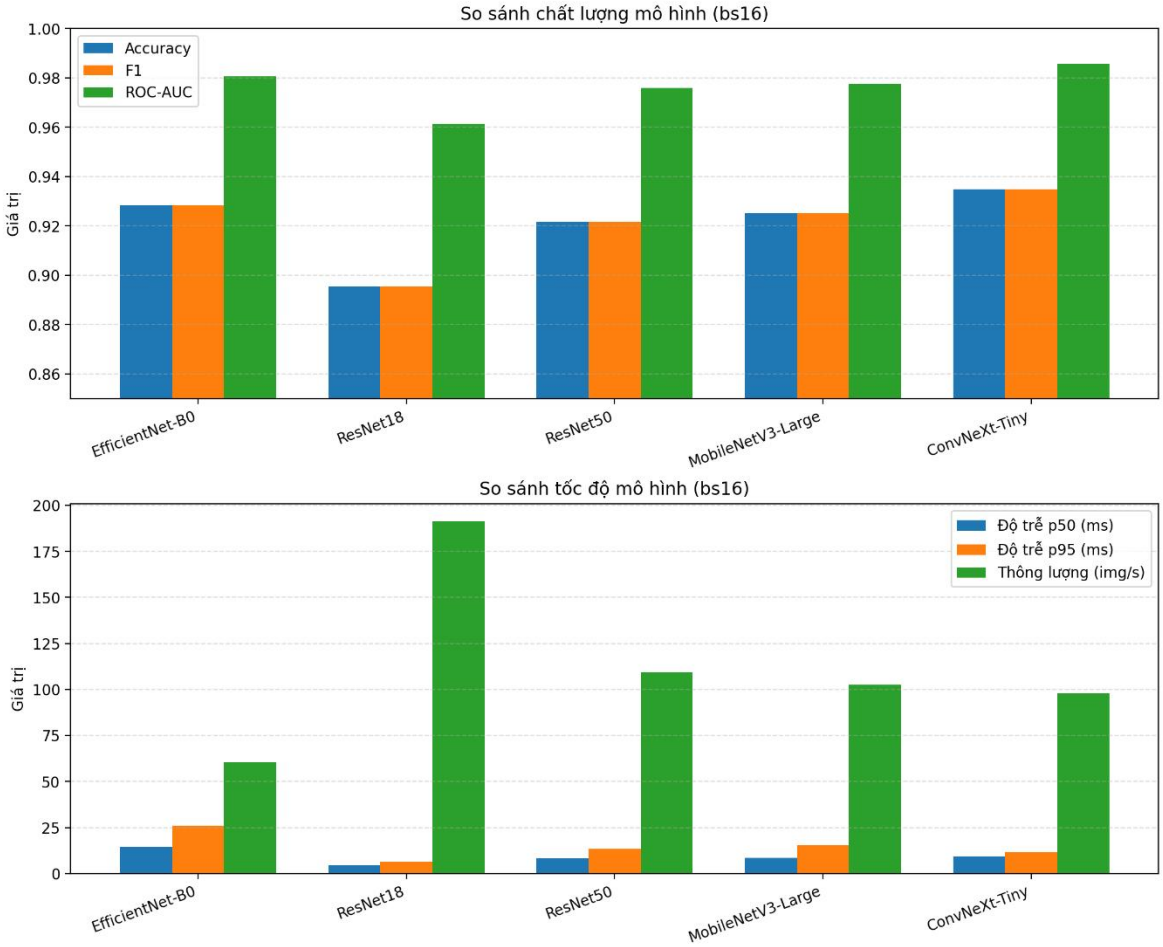

Bảng 5.1. bảng so sánh hiệu năng các mô hình

Kết quả trong Bảng 5.1 cho thấy ConvNeXt-Tiny đạt hiệu năng cao nhất với Accuracy và F1-score vượt trội so với các mô hình còn lại. Tuy nhiên, mô hình này có độ trễ suy luận lớn hơn, gây hạn chế trong triển khai thực tế.

EfficientNet-B0 đạt độ chính xác cao và ổn định, đồng thời có thời gian suy luận thấp hơn ConvNeXt-Tiny, do đó được lựa chọn làm mô hình chính cho hệ thống. ResNet18 có tốc độ nhanh nhất nhưng độ chính xác thấp hơn, trong khi MobileNetV3-Large phù hợp với các môi trường hạn chế tài nguyên.

5.2 Confusion Matrix

Confusion Matrix được sử dụng để đánh giá chi tiết số lượng mẫu dự đoán đúng và sai theo từng lớp. Đây là chỉ số quan trọng giúp hiểu rõ mô hình dễ nhầm lẫn ở lớp nào và mức độ sai lệch ra sao.

Trong thí nghiệm, Confusion Matrix được tính trên tập test cho từng mô hình. Kết quả cho thấy các mô hình có xu hướng cân bằng giữa hai lớp, tuy nhiên vẫn có một tỷ lệ nhỏ ảnh AI bị nhầm thành ảnh thật và ngược lại. Điều này cho thấy bài toán phân biệt ảnh thật/giả vẫn còn khó khăn, đặc biệt khi ảnh AI có chất lượng rất cao.

Việc quan sát Confusion Matrix giúp xác định các trường hợp nhầm lẫn phổ biến để cải thiện dữ liệu hoặc điều chỉnh mô hình trong các bước huấn luyện tiếp theo. Ngoài ra, confusion matrix cũng hỗ trợ việc so sánh trực quan giữa các mô hình, từ đó lựa chọn mô hình phù hợp nhất cho triển khai hệ thống.

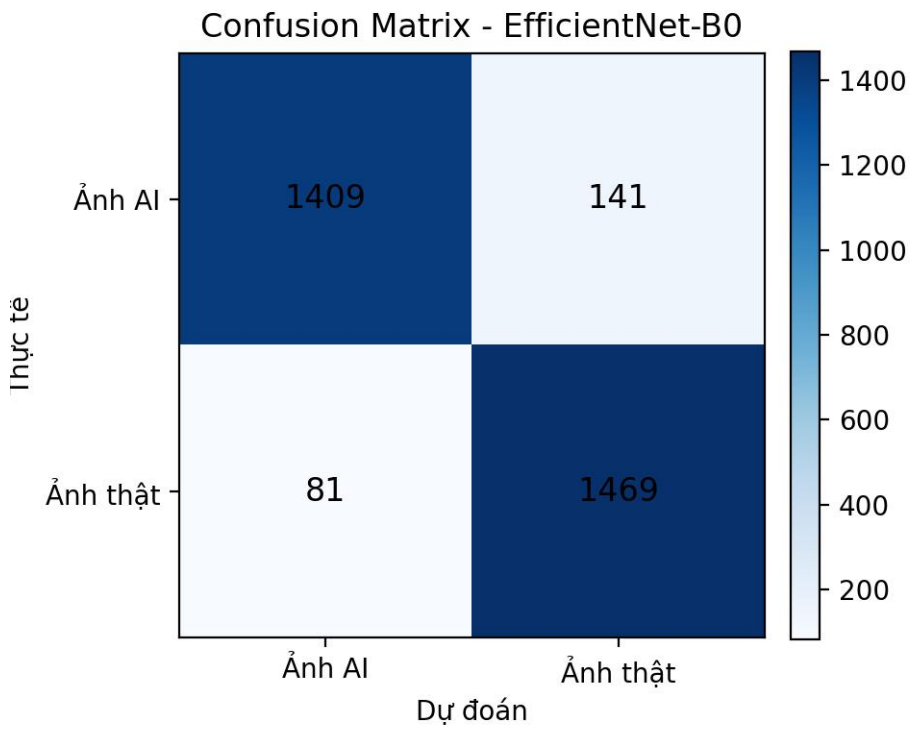

Hình 5.2 Confusion Matrix của EfficientNet-B0

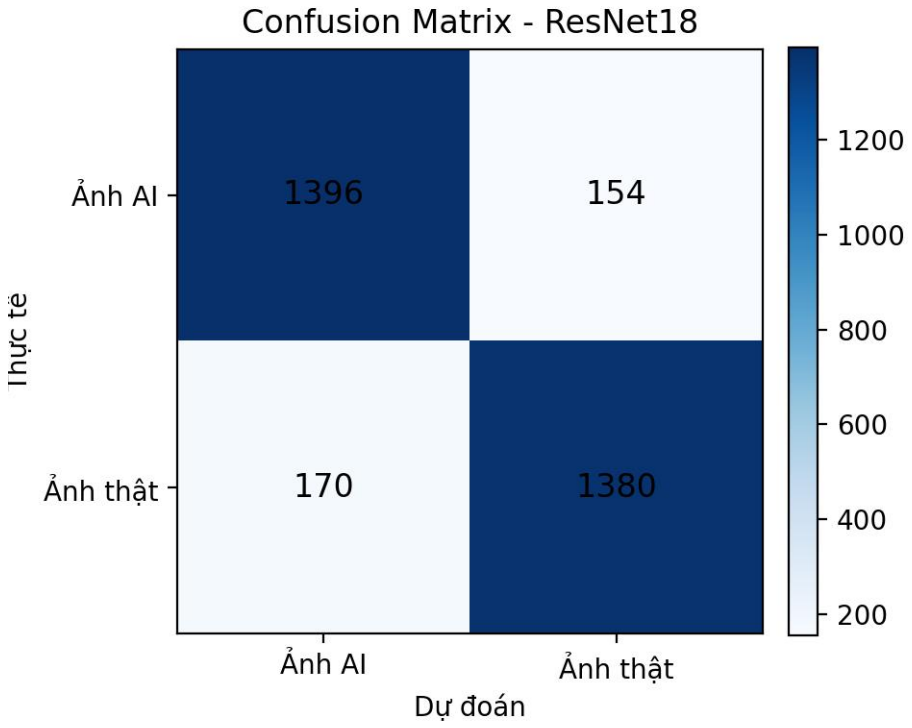

Hình 5.3 Confusion Matrix của ResNet18

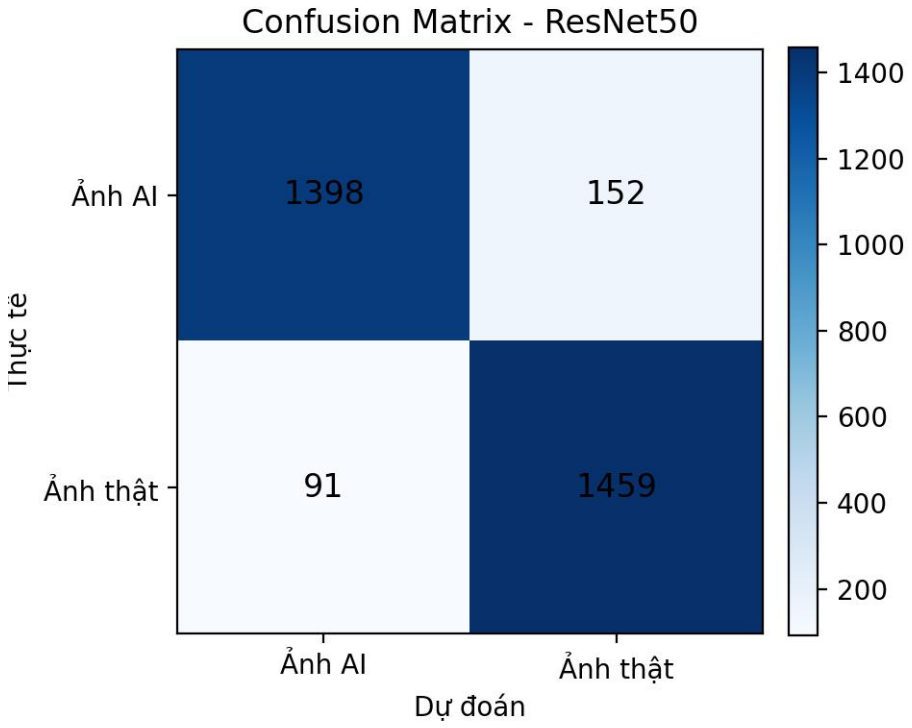

Hình 5.4 Confusion Matrix của ResNet50

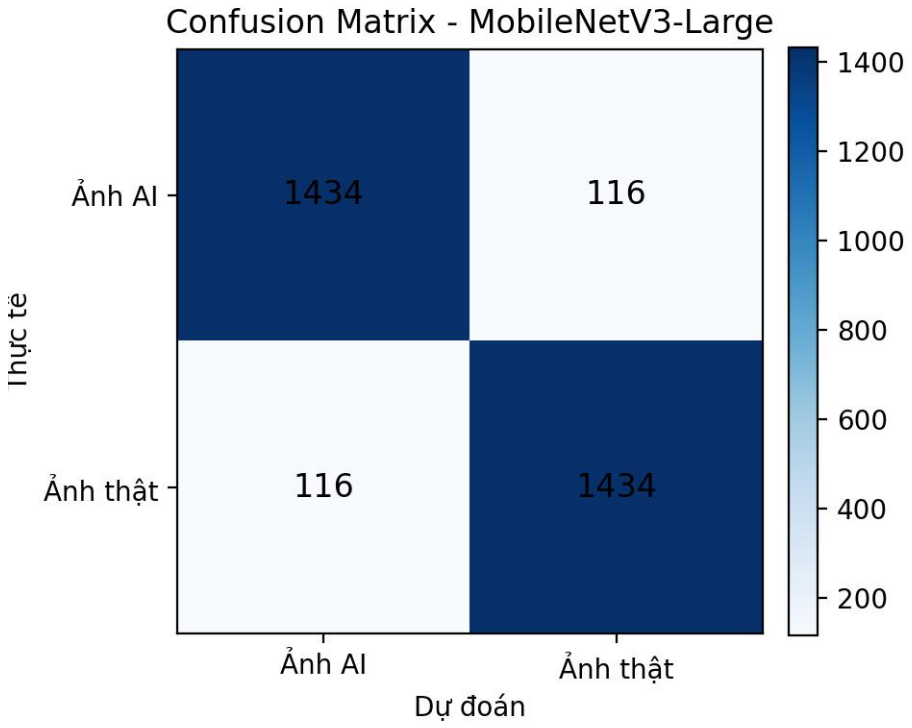

Hình 5.5 Confusion Matrix của MobileNetV3-Large

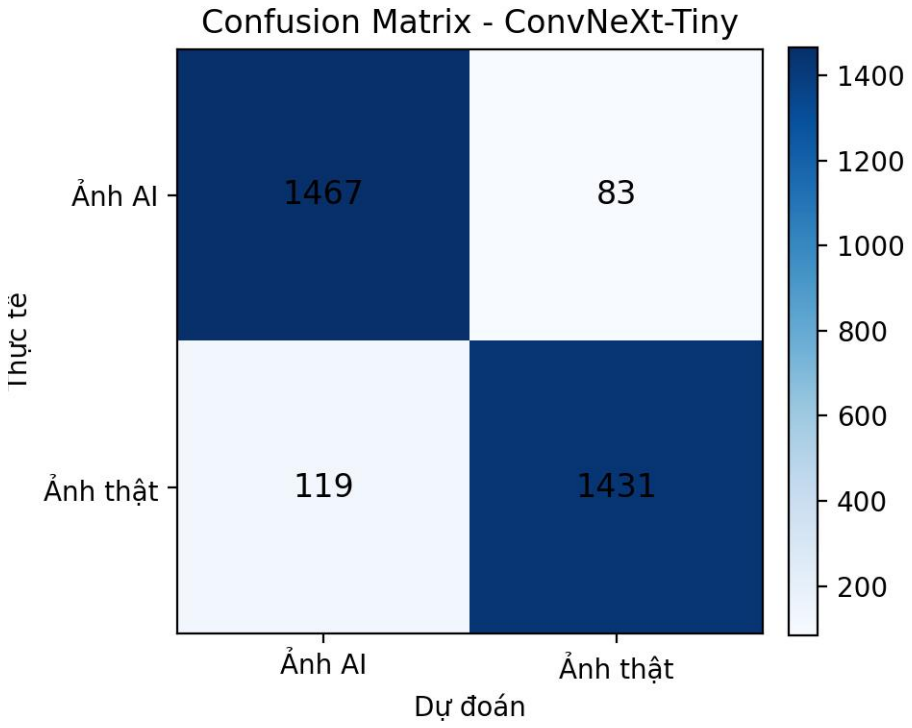

Hình 5.6 Confusion Matrix của ConvNeXt-Tiny

5.3 Grad-CAM kết quả

Để đánh giá khả năng giải thích của hệ thống, Grad-CAM được áp dụng lên các ảnh thử nghiệm thuộc cả hai lớp: ảnh thật và ảnh do AI tạo. Kết quả Grad-CAM thể hiện vùng ảnh mà mô hình tập trung khi đưa ra dự đoán, qua đó giúp người dùng hiểu rõ hơn lý do phân loại.

Với ảnh thật, heatmap thường tập trung vào các vùng có cấu trúc tự nhiên như chi tiết khuôn mặt, bề mặt vật thể hoặc vùng ánh sáng/đổ bóng ổn định. Điều này cho thấy mô hình dựa vào các đặc trưng tự nhiên và nhất quán để kết luận ảnh là thật.

Với ảnh AI, Grad-CAM thường tập trung vào các vùng có dấu hiệu bất thường như kết cấu lặp, chi tiết bị mờ, các vùng chuyển tiếp không tự nhiên hoặc khu vực có độ sắc nét không đồng nhất. Những vùng này là dấu hiệu mô hình dùng để phân biệt ảnh giả, đặc biệt với các ảnh do AI tạo tinh vi.

Kết quả Grad-CAM giúp tăng tính minh bạch cho hệ thống, hỗ trợ người dùng kiểm chứng trực quan và là công cụ hữu ích để phân tích lỗi khi mô hình dự đoán sai. Đây là một điểm mạnh quan trọng trong hệ thống phân tích ảnh thật/giả của đề tài.

Hình 5.7 Grad – CAM minh họa

CHƯƠNG 6 THẢO LUẬN

6.1 Mô hình nào tốt nhất và lý do

Kết quả benchmark cho thấy mỗi mô hình có ưu điểm riêng. ConvNeXt-Tiny đạt chất lượng dự đoán cao nhất (F1 và ROC-AUC cao), chứng tỏ khả năng phân biệt ảnh thật/giả rất tốt. ResNet18 có tốc độ suy luận nhanh nhất nhưng chất lượng thấp hơn so với các model còn lại. MobileNetV3-Large cân bằng giữa tốc độ và độ chính xác, phù hợp môi trường hạn chế tài nguyên.

Tuy nhiên, khi xét tiêu chí cân bằng giữa chất lượng – tốc độ – tài nguyên, EfficientNet-B0 là lựa chọn phù hợp nhất cho hệ thống. Mô hình này đạt độ chính xác cao, ổn định trên tập test, nhưng vẫn đảm bảo độ trễ suy luận chấp nhận được để triển khai thực tế. Đồng thời, EfficientNet-B0 có kiến trúc tối ưu hóa giúp sử dụng tài nguyên hiệu quả hơn so với các model nặng như ResNet50 hay ConvNeXt-Tiny.

Vì vậy, trong phạm vi dự án, EfficientNet-B0 được chọn làm mô hình chính để đảm bảo hệ thống vừa có hiệu năng tốt, vừa dễ triển khai và vận hành lâu dài.

6.2 Phân tích vùng chú ý (grad-cam)

Grad-CAM được sử dụng để quan sát vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. Kết quả cho thấy mô hình không chỉ dựa vào toàn bộ ảnh mà thường chú ý đến một số vùng đặc trưng có tính quyết định. Với ảnh thật, heatmap thường tập trung vào các khu vực có cấu trúc tự nhiên như chi tiết da, tóc, ánh sáng hoặc rìa vật thể rõ ràng. Điều này cho thấy mô hình học được các đặc trưng ổn định và nhất quán trong ảnh thật.

Ngược lại, với ảnh AI, Grad-CAM thường làm nổi bật các vùng có dấu hiệu bất thường như bề mặt bị lặp chi tiết, vùng chuyển tiếp không mượt, hoặc phần ảnh có độ sắc nét không đồng đều. Đây là những đặc trưng khó nhận biết bằng mắt thường nhưng mô hình vẫn khai thác được để phân biệt ảnh giả.

Việc trực quan hóa vùng chú ý giúp tăng tính minh bạch cho hệ thống và hỗ trợ giải thích kết quả cho người dùng. Đồng thời, Grad-CAM cũng là công cụ hữu ích để phân tích các trường hợp dự đoán sai, từ đó điều chỉnh dữ liệu hoặc cải thiện mô hình trong các lần huấn luyện tiếp theo.

6.3 Hạn chế của hệ thống

Mặc dù hệ thống đạt kết quả tốt trong thí nghiệm, vẫn tồn tại một số hạn chế cần được thừa nhận. Thứ nhất, dữ liệu ảnh AI thay đổi rất nhanh theo sự phát triển của các mô hình tạo ảnh mới. Mô hình hiện tại có thể giảm hiệu quả khi gặp dạng

ảnh giả mới mà chưa từng xuất hiện trong tập huấn luyện. Điều này cho thấy nhu cầu cập nhật dữ liệu và huấn luyện lại định kỳ.

Thứ hai, môi trường đánh giá còn giới hạn. Các thí nghiệm chủ yếu thực hiện trên tập dữ liệu chuẩn hóa, trong khi ảnh thực tế có thể bị nén mạnh, bị nhiễu, hoặc chụp từ thiết bị khác nhau. Những yếu tố này có thể ảnh hưởng đến độ chính xác khi triển khai ngoài thực tế.

Thứ ba, chi phí tính toán vẫn là một rào cản, đặc biệt với những mô hình có chất lượng cao nhưng nặng như ConvNeXt-Tiny. Ngoài ra, Grad-CAM tuy giúp tăng tính minh bạch nhưng cũng làm tăng thời gian suy luận và tiêu thụ tài nguyên.

Những hạn chế này gợi ý rằng hệ thống cần tiếp tục được mở rộng dữ liệu, tối ưu hiệu năng và kiểm thử trên môi trường thực tế đa dạng hơn để đạt độ tin cậy cao khi triển khai quy mô lớn.

CHƯƠNG 7 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

7.1 Kết luận

Đề tài đã xây dựng thành công hệ thống phân loại ảnh thật/giả do AI tạo dựa trên mô hình học sâu. Hệ thống hỗ trợ suy luận qua API, giao diện web trực quan và có khả năng giải thích kết quả bằng Grad-CAM. Kết quả thực nghiệm cho thấy các mô hình CNN hiện đại đạt độ chính xác cao, trong đó EfficientNet-B0 là lựa chọn cân bằng tốt giữa chất lượng và hiệu năng. Bên cạnh đó, hệ thống còn lưu lịch sử dự đoán để phục vụ kiểm tra và đối chiếu, giúp tăng tính minh bạch trong quá trình sử dụng. Tổng thể, đề tài đã đạt được mục tiêu đề ra, chứng minh tính khả thi của việc ứng dụng deep learning để phát hiện ảnh AI trong môi trường thực tế.

7.2 Hướng phát triển

Trong tương lai, hệ thống có thể được mở rộng bằng cách áp dụng các kiến trúc mới như Vision Transformer nhằm nâng cao độ chính xác, đồng thời bổ sung dữ liệu đa dạng hơn để tăng khả năng tổng quát hóa. Việc mở rộng bài toán sang deepfake video sẽ giúp hệ thống đáp ứng nhu cầu thực tế cao hơn. Ngoài ra, cần tối ưu hiệu năng và triển khai trên server hoặc ứng dụng di động để phục vụ nhiều người dùng. Cuối cùng, có thể kết hợp thêm các kỹ thuật Explainable AI khác nhằm tăng tính minh bạch và độ tin cậy của hệ thống.

TÀI LIỆU THAM KHẢO

1. Hsu, C.-C., Hung, T.-Y., Lin, C.-W., & Hsu, C.-T. (2022). *Deepfake video detection based on EfficientNet-V2 network*. **Computational Intelligence and Neuroscience**, 2022, Article 3441549. https://doi.org/10.1155/2022/3441549
2. Vina, A. (2025, August 29). *What is EfficientNet? A quick overview*. Ultralytics. https://www.ultralytics.com/vi/blog/what-is-efficientnet-a-quick-overview
3. AICandy. (n.d.). *Mô hình ResNet – Đột phá trong nhận diện hình ảnh* [Slides]. SlideShare. https://www.slideshare.net/slideshow/mo-hinh-resnet-d-t-pha-trong-nh-n-di-n-hinh-nh-pdf/273803943
4. Almutairi, Z. M., & Alenezi, F. S. (2025). *Deep learning-based approach for detecting AI-generated images*. **Computer Vision and Image Understanding**. https://doi.org/10.1016/j.cviu.2025.104326
5. Heidari, A., Jafari Navimipour, N., Dag, H., & Unal, M. (2024). *Deepfake detection using deep learning methods: A systematic and comprehensive review*. **WIREs Data Mining and Knowledge Discovery, 14**(2), e1520. https://doi.org/10.1002/widm.1520
6. Thing, V. L. L. (2023). *Deepfake detection with deep learning: Convolutional neural networks versus transformers*. arXiv. https://doi.org/10.48550/arXiv.2304.03698